

进度汇报:手册管线重构(2026-07-21 → 07-28)

汇报人:Xiangzhu Yan

时间跨度:上次周报(7月21日)至今

一句话总结:我们用一周时间完成了手册系统的"地基更换"——从"临时解析、无质检"升级为"独立索引 + 出厂验收",四个阶段全部开发完毕,前三个已合入主线;对比评测已完成,结论:**建议切换生产**(可一键回退)。

一、起点:上周暴露的问题

上周周报里,手册问答的30道专家测试题平均分是**0.831**,其中4道题长期低分。我们对最低分的一道(0.483)做了完整解剖,发现了一个危险的失败模式:

手册里**明明有** P0335 故障码的完整诊断表, AI 却自信地回答"手册里没有这个内容"——放在车间里,这会直接误导技师。

顺藤摸瓜,我们把根源挖了出来:**系统的"目录"是每次临时从转换软件猜的标题里拼出来的**。转换软件(把 PDF 变成文本的工具)擅长搬运文字,但不擅长理解文档结构——它猜出来的标题 40% 是噪音、12% 的章节是空壳、22 个故障码里 13 个在目录上根本找不到入口。整套问答系统就建在这个不可靠的地基上,而且**没有任何质检环节能提前发现这些问题**——只能等测试分数变差才暴露。

二、本周做的事:换地基

打个比方:以前我们的"图书馆"是每次开馆时,照着装订工猜的目录页临时手抄一份索引卡;装订工猜漏的书,卡片上就写着"本馆无此书"。本周我们把它改成了**正规的图书馆流程**——一个先堵出血点的"先行修复"(第 0 步),加四步系统改造:

0. 先行修复:给 AI 配上 Ctrl+F,并立下"证伪才能说没有"的规矩(本周初已上线生产)。

大改造需要时间,但开头那种"自信说没有"的危险失败等不起,所以我们先做了一个不依赖新地基的小修复单独上线:①给 AI 新增全文检索工具(此前它找资料只能翻那份不可靠的目录);②立一条铁律——宣称"手册里没有 X"之前,必须先全文检索且零命中;③把目录里误导性的"-"标记(曾被 AI 读作"手册没有")改成明确的"内容存在,请用检索定位"。这个小包上线一周,是后文"现行系统涨到 0.870"的主要功臣——本周投入的第一笔已兑现回报。

1. 书的内容保证一页不丢(存储层)。

不再指望任何单一转换软件。文字直接从 PDF 原文提取(数学上保证 100% 完整),转换软件降级为"排版顾问";它丢掉的 48 个复杂表格,我们按坐标从 PDF 原图救回,其中 40 个恢复成了可以按行按列读的结构化表格。每次生成内容都有一道**逐行对账**:原文 12,200 行,少一行都不许出厂。本周实测:**缺失 0 行,100.0000%**。

2. 独立制作索引卡(索引层)。

每本手册配一份"电子索引卡":464 个章节的真实目录树、22 个故障码的直达卡片(症状、失效保护、维修入口一应俱全)、每节的类别标签和一句话简介。制卡有**9 道自动验收**(内容全覆盖、无空壳、故障码全收录、引用可解析.....),任何一道不过,索引不许上架。验收员本身也被测试过:我们故意制造 12 种坏索引,验证每种都会被拦下。

3. AI 换上新导航(查询层)。

AI 现在有四条查资料的通道:按故障码直达卡片、按类别浏览目录、按关键词全文检索、以及一条铁律——"**说手册里没有**"之前**必须先全文检索证明**(正是防止开头那种自信错答的)。新旧两套系统**双轨并存**,一个开关即可切换,切换风险为零。

4. 专家资产原样保护。

30 道测试题是维修专家花了大量线下时间构建的。系统换了,题目的"语义"一字未动,只把题目里的"定位信息"自动重映射到新索引(25 个定位点全部成功转换),专家无需返场。

三、已经落袋的量化成果

指标	数字	说明
文字完整性	100.0000%(12,200/12,200 行)	逐行对账,构建时强制
表格恢复	48 个丢失表格全部救回,40 个恢复结构	零新增软件依赖
故障码收录	22/22 全部有直达卡片	之前 13 个无入口
单元格级问答探针	20/20 通过(100%)	气门间隙、胎压、扭矩等最刁钻的表格值,全部可查可读且不串行
先行修复(已上线生产一周)	最差题 0.483 → 0.937(旧系统上实测)	"自信说没有"的失败模式已消灭;问题在新索引系统上 0.977
生产系统当前水平	平均 0.870、30/30 过线(今晨实测)	较上周 0.831 提升,主要来自已上线的先行修复

另外:全流程对第二本手册**可复用**——接入新手册只需跑一条命令,所有质检自动执行。这是本次重构的核心目的:不是修一本手册,是建一条流水线。

四、对比评测结果

新索引系统与现行系统做了背靠背盲测(同样 30 道题、同一评分标准、多轮取平均,避免单轮波动误导):

场次	平均分	备注
现行系统 第 1 轮	0.870	
现行系统 第 2 轮	0.872	两轮均值 0.871 ,轮间方差仅 0.002,对照组极稳定
新索引系统 第 1 轮	0.806	修复前;暴露 2 个可修问题,当天修复
新索引系统 第 2 轮	0.877	修复后的完整一轮,实测口径
修复后定向验证	折算 0.895	仅重跑受影响的 2 题(0.383→0.718、0.608→0.818),代入第 2 轮成绩后的估算均值;非全量重跑,最终背书以观察期的全量对照为准

核心结果:新索引系统(0.877)**超过现行系统两轮均值(0.871)**;四道历史低分题全部拉到 0.94 以上;中位数 0.937 vs 0.896,分布更紧。

新系统涨分集中在"拒答有底气""程序不丢步"这类结构化收益;第 1 轮曾被两道题拖累,病因当天定位并修复(一处是查询解析、一处是评分记录方式),定向验证已生效——即上表折算 0.895 的来源。

建议(数据已齐):旧系统两轮均值 **0.871**(极稳定);新索引系统实测 **0.877**、修复折算 **0.895**;四条历史低分全部 >0.94,探针

20/20。 **正式建议:切换生产**——旧系统整体保留,一个开关随时回退,观察期内补一轮全量对照作最终背书。

五、风险、诚实说明与决策框架

如何正确理解“均值只差 0.007”:先行修复(Ctrl+F)已经把“内容找得到”的红利收割完了——这 30 道题问的都是两套系统如今都够得着的内容,所以均值差距天然收窄。索引重建的价值主张主要在这份考卷**测不到**的四个地方:

1. **内容完整性**:旧存储缺约 7.3% 的文字(图内标注、48 个表格、若干错值),考卷恰好没抽中,车间技师未必不会问到;新存储 100% 由构造保证。
2. **可维护性**:旧系统的 0.870 是两年补丁堆出来的(每次生产事故修一个症状);新系统把同类问题变成“制卡当天报错”,不再靠分数变差来发现。
3. **可扩展性**(立项的第一动机):接第二本手册,旧路线要重新踩排版坑,新路线是一条命令 + 自动质检。这一条的真正考卷是下阶段的 Corolla 验证,不是这 30 题。
4. **拒答质量**:考卷上已可见——最难的“假前提”类题,新系统靠目录上的故障码卡片给出有底气、有纠正内容的拒答(0.596→0.942)。

因此,切换决策的诚实性质是“架构投资”:同等或略优的分数,换取完整性、可维护性与可扩展性,且旧系统全程保留、一键回退。不将其包装为“benchmark 大涨”。

其余说明:

- 3 个章节标题在新转换下仍无独立条目(旧问题残余),现有三重兜底,已列入下阶段修复清单。
- 扫描版
PDF(无文字层)尚未支持——现有两本手册都是原生文字版;第一本扫描件到达时启动(已建占位任务)。

六、下一步

1. **切换决策(决策点和管理侧)**:第四节结论即建议书;获批后部署切换,旧系统保留观察期,一键回退。
2. **收尾工程(1 天内)**:阶段文档更新 + PR 合入;观察期内补一轮公平口径的全量对照作最终背书。
3. **优化全量测试运行时间**:目前一轮 30 题约 50-60 分钟(本地推理串行 + 判卷串行),是本周迭代节奏的主要瓶颈;方向包括判卷并行化、题目分批并发、结果缓存复用,目标压到 20 分钟以内。
4. **下一阶段(Phase 4,约 2 天)**:用第二本手册(丰田 Corolla,英文)完整走一遍流水线,验证“可复用”不是口号;产出新手册接入操作手册。
5. 待办移交项:生产上传通道的转换 worker 仍在用旧流程,切换获批后一并迁移。

附:过程数据与全部评测报告已入库(docs/eval-reports/ 下 harness30 系列),索引规范文档 docs/manual_index_spec.md,实施计划 docs/manual_pipeline_topdown_plan.md。