

评测体系提速 7.5 倍、评分基准修复与模型换代决策

作者 Xiangzhu Yan · 周期 2026-07-31 – 08-01 · 面向 PM 周会

80.5 → 10.7 分

钟
全量评测耗时(7.5×)

0.889

修复后的质量基准分(满分 1)

\$10.4

本周全部云端实验费用

5 合并 / 1 待办

PR 与工程任务

一句话总结

本周把“给 AI 诊断系统打分”从 **80 分钟压到 10 分钟**,顺手挖出并修复了一个让历史分数**虚假下跌**的评分错误;然后利用变快的评测,在两天内完成一次**模型换代选型**和一次“**最贵的模型值不值**”的对照实验,云端总花费约 10 美元。核心发现:**我们免费本地部署的 27B 小模型,与参数量大 100 倍、按量收费的顶级模型,在我们的任务上得分几乎相同。**

背景:为什么做这件事

我们用一套 30 道专家审定的维修问答“考卷”(golden 测试集)衡量系统质量,每次改动后重考,防止退步。问题是**考一次要 55–80 分钟**:上周手册索引项目一次 A/B 对比烧掉 3.5 小时,“改一行代码 → 看分数”要等一小时——评测速度成了整个研发节奏的瓶颈。本周目标(#225):20 分钟以内。

成果一 · 评测提速 80.5 → 10.7 分钟(超额完成)

80.5 分钟 → 54.6 → 26.6 → **10.7 分钟** (每一步分数验证一致)

- 判卷与答题并行(→54.6 分钟)**:判卷走云端服务、不占本地显卡,重构后判卷完全隐藏在下一题的答题时间里。验收:同日同内容对照,0.790 vs 0.791。
- 双显卡各跑一份模型(→26.6 分钟)**:原计划的“一份模型批量答题”被推理软件的兼容性挡住(Ollama 不支持该模型批处理),改为两卡各部署一份、两题真并行。验收:分数分毫不差。
- 换工业级推理引擎 vLLM(→10.7 分钟)**:原生批处理(6 题同时答)+ 真正吃满双卡,随模型换代一并落地。

10.7 分钟已接近物理下限——最长的一道题本身就要串行跑约 4 分钟,再快就要改产品本身了。

成果二 · 挖出让全系统“虚假掉分”的评分错误(#234)

发现:提速改动验收时分数从 0.891 掉到 0.790;同日对照证明旧代码也是 0.790——掉分与提速无关,系统“两天前就退步了”。

排查(三步、零 GPU 占用):① 把两天前的高分答卷交给今天的判卷系统重判,分数复现(0.891→0.898),排除判卷方;② 解剖分数构成——掉分全部集中在"引用章节编号对号入座"维度,而答案内容质量反而**上升**;③ 锁定根因:上周索引项目切换了章节编号体系,当时使用的"新格式标准答案"只是服务器上的临时文件、**从未写入代码**,被一次常规代码同步冲掉——此后系统用新编号引用、考卷按旧编号对答案,全线虚假扣分。

修复:答案文件的选择逻辑写进代码、随索引开关自动切换。修复后重考 **0.889,与历史基准吻合——系统从未真正退步**。

教训入档 任何影响评分的配置必须进代码仓库,不能依赖服务器上的手工文件状态——那种状态会在下一次代码同步时无声消失。

成果三 · 模型换代选型:新模型转正

代码完全冻结、只换模型、同一套考卷考两轮取平均:

候选	两轮平均分	不及格题	考一轮耗时	结论
现役 qwen3.5-27B(参照)	0.889	0	51 分钟	—
新 Qwen3.6-27B	0.881(持平)	0	10.7 分钟	✓ 转正
新 Qwen3.6-35B(MoE 轻量版)	0.815	2-3(稳定复现)	6.5 分钟	✗ 淘汰

- **35B 落选很有教育意义**:名义参数更大,但采用"每次只动用 3B 参数"的省算力架构(MoE),等效能力约 10B 级;它每轮都在同样的题上以同样方式失败(过早放弃查手册、输出格式失守)。**按名义参数量选型是陷阱,必须实测**。
- 选型过程附带逼出并修复了 2 个潜伏代码缺陷——"换个环境跑一遍"的额外价值。
- 生产环境正式切换已立项(#237),待排期。

成果四 · "最贵的模型值不值"对照实验(总花费约 \$10)

模型	参数量	平均分	考一轮耗时	考一轮费用
本地 Qwen3.6-27B	27B	0.881	10.7 分钟	0 元(实验室服务器)
GLM-5.2(智谱旗舰)	744B	0.876	3.9 分钟	~\$3-6
Kimi K3(月之暗面旗舰)	2.8T	0.888	6.0 分钟	~\$6-8

参数量跨越两个数量级,分数在同一条误差带内——没有质变。更有说服力的细节:所有模型考不好的题**错得分毫不差**(某题三个模型同得 0.578)——瓶颈在考题的答案口径与评分尺度,不在模型能力。唯一随规模上升的是"该拒答时拒答"的判断力(+0.075),幅度有限。

对架构的意义(已写入设计文档 §8.4)

- **系统能力主要来自自建"脚手架"**(手册索引、工具纪律、提示工程),不来自模型参数——投在脚手架上的每一分钱都在免费升级所有模型;
- **窄任务子模块用最便宜的够用模型**——与业界实践一致(业界实测异构配模省 40-60% 成本;我们因子模块完全本地化,节约比例更高);

- 贵的模型只花在刀刃上:调度决策、拒答判断、未知任务探路;
- 今后每个新模块上线前跑一轮选型(现仅需 4-10 分钟/模型)。

负结果(也是结果)

- **MTP 投机解码**(理论无损的加速技术):实测更慢(11.1 vs 10.7 分钟)且分数有可疑波动,已回滚记档。原因:它加速"逐字生成"段,而我们的瓶颈在"批量读入手册"段——加速了不痛的地方。
- **15 路高并发**:并行度非越大越好,实测 6-8 路为最优点;15 路反而更慢并引发超时。6 路已定为标准配置。

数字汇总与下周建议

项目	数据
评测耗时	80.5 → 54.6 → 26.6 → 10.7 分钟 (累计 7.5×)
质量基准	0.889(修复 #234 后重新封存,经四方模型交叉验证)
本周云端实验费用	约 \$10.4(含约 250 次判卷调用)
代码变更	5 个 PR 全部合并(#233 / #235 / #236 / #238 + 周报);潜伏缺陷修复 3 个
待排期	#237 新模型 + vLLM 生产切换

下周建议(待讨论):① 执行 #237 生产切换与端到端验证;② 修"慢性低分题"——四个模型共同证明其丢分是答案口径问题,修口径 = 涨分 + 提速 + 降低用户等待,一举三得;③(远期)待端到端测试集就绪后,量化"大模型调度 + 小模型执行"在完整业务流上的真实节约。